

UNIVERSIDAD EUROPEA Grandes Volúmenes de Datos

Contenido

| | | 0 |
|------|--|---|
| Cont | enido | 1 |
| | Obtén una imagen de Hadoop para Docker: Puedes buscar en Docker Hub una imagen dop que alguien más haya creado | |
| a. | Iniciar y verificar el contenedor de Hadoop | 2 |
| 2. | Practica Hadoop | 3 |
| a. | Crear un nuevo directorio en HDFS | 3 |
| b. | Copiar los archivos al contenedor | 3 |
| c. | Listar los archivos en el directorio HDFS creado | 3 |
| d. | Leer el contenido de los archivos (Sustituye localfile.txt son los archivos descargados): | 4 |
| 3. | Operación map-reduce | 4 |

- 1. Obtén una imagen de Hadoop para Docker: Puedes buscar en Docker Hub una imagen de Hadoop que alguien más haya creado.
- a. Iniciar y verificar el contenedor de Hadoop

Para verificar que nuestra instalación de Hadoop se ha realizado correctamente deberemos de ejecutar el siguiente comando:

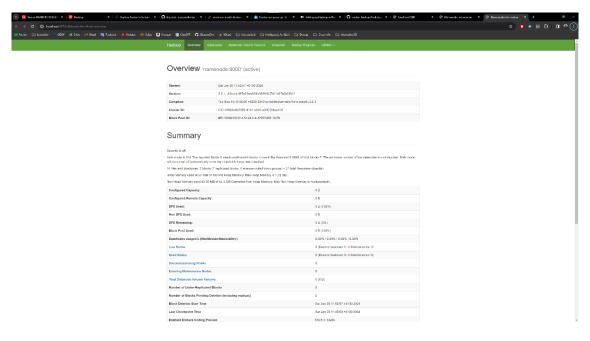
```
C:\Users\Javie\Desktop\Actividad 02
λ docker exec -it 8e74a7e3953b hadoop version
Hadoop 3.2.1
Source code repository https://gitbox.apache.org/repos/asf/hadoop.git -r b3cbbb467e22ea829b3808f4b7b01d07e0bf3842
Compiled by rohithsharmaks on 2019-09-10T15:56Z
Compiled with protoc 2.5.0
From source with checksum 776eaf9eee9c0ffc370bcbc1888737
This command was run using /opt/hadoop-3.2.1/share/hadoop/common/hadoop-common-3.2.1.jar
```

Como podemos ver hemos instalado la versión 3.2.1 de Hadoop.

Podemos comprobar que funciona correctamente utilizando un comando sencillo como listar el directorio raíz dentro del sistema a de Hadoop, para ello hemos usado los siguiente:

```
C:\Users\Javie\Desktop\Actividad 02
\( \lambda\) docker exec -it 8e74a7e3953b hdfs dfs -ls /
Found 1 items
drwxr-xr-x - root supergroup 0 2024-01-20 10:47 /rmstate
```

También podemos verificar la instalación conectándonos al nodo vía web:



2. Practica Hadoop

a. Crear un nuevo directorio en HDFS

Para poder crear un nuevo directorio en Hadoop simplemente nos conectaremos al contenedor correspondiente y ejecutaremos el comando mkdir seguido de la carpeta a crear:

```
C:\Users\Javie\Desktop\Actividad 02
λ docker exec -it 8e74a7e3953b hdfs dfs -mkdir /test
```

b. Copiar los archivos al contenedor

Para copiar los archivos que se han descargado para la práctica deberemos de usar el comando put dentro de Hadoop, podemos ver un ejemplo en la siguiente captura:

```
C:\Users\Javie\Desktop\Actividad 02

λ docker exec -it 8e74a7e3953b hdfs dfs -put /datos /test
2024-01-20 11:19:11,298 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:11,796 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:12,299 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:12,299 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:12,291 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:13,653 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:13,197 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:15,366 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:15,366 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:15,366 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:16,003 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:16,011 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:16,041 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024-01-20 11:19:16,401 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2024
```

Cabe destacar que los datos fueron descargados previamente y guardados en la carpeta /datos.

c. Listar los archivos en el directorio HDFS creado

Una vez todos los datos hayan sido copiados deberemos de listar la carpeta contenedora de los mismos para verificar su correcto copiado, podemos verlo en la siguiente caputra:

```
C:\Users\Javie\Desktop\Actividad 02

λ docker exec -it 8e74a7e3953b hdfs dfs -ls /test/datos
Found 13 items
-rw-r--r-- 3 root supergroup 103939 2024-01-20 11:19 /test/datos/games.csv
-rw-r--r-- 3 root supergroup 53546466 2024-01-20 11:19 /test/datos/players.csv
-rw-r--r-- 3 root supergroup 18561101 2024-01-20 11:19 /test/datos/tackles.csv
-rw-r--r-- 3 root supergroup 180879231 2024-01-20 11:19 /test/datos/tracking_week_1.csv
-rw-r--r-- 3 root supergroup 180879231 2024-01-20 11:19 /test/datos/tracking_week_2.csv
-rw-r--r-- 3 root supergroup 186949967 2024-01-20 11:19 /test/datos/tracking_week_3.csv
-rw-r--r-- 3 root supergroup 186949967 2024-01-20 11:19 /test/datos/tracking_week_4.csv
-rw-r--r-- 3 root supergroup 164721387 2024-01-20 11:19 /test/datos/tracking_week_5.csv
-rw-r--r-- 3 root supergroup 170426365 2024-01-20 11:19 /test/datos/tracking_week_7.csv
-rw-r--r-- 3 root supergroup 185526698 2024-01-20 11:19 /test/datos/tracking_week_8.csv
-rw-r--r-- 3 root supergroup 151477618 2024-01-20 11:19 /test/datos/tracking_week_9.csv
```

d. Leer el contenido de los archivos (Sustituye localfile.txt son los archivos descargados):

Por último, podremos leer los datos utilizando el comando cat, a continuación se muestra una captura con el contenido de uno de los csv:



3. Operación map-reduce

La operación map-reduce que se ha utilizado ha sido para contar el número de pesos que se repiten en el archivo players.csv. En primer lugar, se obtenido el contenido del fichero csv, una vez se ha almacenado en una variable se divide en líneas haciendo un Split mediante el salto de carro (\n). Una vez tengamos divididas las líneas simplemente se ejecuta un bucle foreach que recorre cada una de las mismas. Por cada línea se realiza otro Split usando como separador el carácter ",". Obtenemos la altura y la almacenamos para ser contada.

```
public class CustomMapper extends MapReduceBase implements Mapper ! Mapper is a raw type. References to gener:
    private final static IntWritable one = new IntWritable(value:1);
    private String[] lines;

@Override
    public void map(Object key, Object value, OutputCollector output, Reporter reporter) throws IOException {
        String content = value.toString();
        lines = content.split(regex:"\n");

        for (String line : lines) {
            int weight = Integer.valueOf(line.split(regex:",")[2]);
            output.collect(weight, one); Type safety: The method collect(Object, Object) belongs to the raw ty
        }
    }
}
```

La segunda parte consta simplemente de obtener los valores anteriores e ir sumando para obtener el número de veces que se repite. Con esto conseguimos obtener el número de personas que tienen el mismo peso.